

1번 암호분석 Caesar/Vigenère 복원과 학습 분류기

암호분석경진대회 제출 보고서

2026년 7월

제출 답 요약

항목	결과
ciphertexts1.txt	Caesar, IC 0.067638 → 0.068 , shift 6
ciphertexts2.txt	Vigenère, IC 0.043972 → 0.044 , key KLV0J, 줄마다 key position 초기화
3-다/4-다 평문	THESOVERYEIGNTYOFTHEREPUBLICOFKOREA SHALLRESIDEINTHEPEOPLEANDALLSTATEAUTHORITY SHALLEMANATEFROMTHEPEOPLE
분류기 holdout	동일 corpus·동일 key 안의 paired line holdout 58/58
관측 가능한 1-4 구조	모두 period-1 Caesar-like, shift 6, 10, 10, 6
출제 의도 추정 라벨	Caesar, Vigenère, Vigenère, Caesar

1 Caesar와 Vigenère

알파벳을 $A = 0, \dots, Z = 25$ 로 나타내면 Caesar는 하나의 shift k 를 모든 위치에 적용한다.

$$C_i = P_i + k \pmod{26}, \quad P_i = C_i - k \pmod{26}.$$

따라서 영어의 불균등한 단문자 빈도와 IC가 보존되고, 빈도표의 문자 이름만 이동한다. key 공간도 26개다.

Vigenère는 길이 r 인 key를 반복한다.

$$C_i = P_i + K_{i \bmod r} \pmod{26}.$$

서로 다른 shift의 빈도분포가 섞여 전체 IC는 균등분포의 $1/26 \simeq 0.0385$ 쪽으로 낮아진다. 반대로 같은 $i \bmod r$ 위치끼리 모으면 각 열이 다시 Caesar가 된다. 길이 1 Vigenère는 Caesar와 수학적으로 완전히 같다는 포함 관계가 마지막 분류 문항에서 중요하다.

2 IC 계산과 암호방식 특정

문자별 횟수를 n_i , 전체 길이를 N 이라 하면

$$\text{IC} = \frac{\sum_i n_i(n_i - 1)}{N(N - 1)}$$

를 계산했다. A-Z 이외의 문자를 제거한 두 파일은 각각 19,897자다.

파일	IC	요구 반올림	판정
ciphertexts1.txt	0.067638	0.068	Caesar
ciphertexts2.txt	0.043972	0.044	Vigenère

영어 평문의 IC는 약 0.065–0.067로 알려져 있다(Friedman). ciphertexts1.txt의 0.068은 이 값과 거의 같아 빈도 분포가 보존된 Caesar로, ciphertexts2.txt의 0.044는 균등분포값 0.0385 쪽에 더 가까워 여러 shift가 섞인 Vigenère로 판정했다.

3 Ceaser 평문 복원

시저 암호로 판단한 ciphertexts1.txt를 가능한 key $k = 0, \dots, 25$ 전체로 복호화하고, 각 복호문에서 A-Z 출현 횟수를 세었다.

k	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W	X	Y	Z
0	428	181	134	45	355	57	1676	459	751	734	2524	495	245	899	1484	37	36	1016	499	1427	1479	444	28	1198	1361	1905
1	181	134	45	355	57	1676	459	751	734	2524	495	245	899	1484	37	36	1016	499	1427	1479	444	28	1198	1361	1905	428
2	134	45	355	57	1676	459	751	734	2524	495	245	899	1484	37	36	1016	499	1427	1479	444	28	1198	1361	1905	428	181
3	45	355	57	1676	459	751	734	2524	495	245	899	1484	37	36	1016	499	1427	1479	444	28	1198	1361	1905	428	181	134
4	355	57	1676	459	751	734	2524	495	245	899	1484	37	36	1016	499	1427	1479	444	28	1198	1361	1905	428	181	134	45
5	57	1676	459	751	734	2524	495	245	899	1484	37	36	1016	499	1427	1479	444	28	1198	1361	1905	428	181	134	45	355
6	1676	459	751	734	2524	495	245	899	1484	37	36	1016	499	1427	1479	444	28	1198	1361	1905	428	181	134	45	355	57
7	459	751	734	2524	495	245	899	1484	37	36	1016	499	1427	1479	444	28	1198	1361	1905	428	181	134	45	355	57	1676
8	751	734	2524	495	245	899	1484	37	36	1016	499	1427	1479	444	28	1198	1361	1905	428	181	134	45	355	57	1676	459
9	734	2524	495	245	899	1484	37	36	1016	499	1427	1479	444	28	1198	1361	1905	428	181	134	45	355	57	1676	459	751
10	2524	495	245	899	1484	37	36	1016	499	1427	1479	444	28	1198	1361	1905	428	181	134	45	355	57	1676	459	751	734
11	495	245	899	1484	37	36	1016	499	1427	1479	444	28	1198	1361	1905	428	181	134	45	355	57	1676	459	751	734	2524
12	245	899	1484	37	36	1016	499	1427	1479	444	28	1198	1361	1905	428	181	134	45	355	57	1676	459	751	734	2524	495
13	899	1484	37	36	1016	499	1427	1479	444	28	1198	1361	1905	428	181	134	45	355	57	1676	459	751	734	2524	495	245
14	1484	37	36	1016	499	1427	1479	444	28	1198	1361	1905	428	181	134	45	355	57	1676	459	751	734	2524	495	245	899
15	37	36	1016	499	1427	1479	444	28	1198	1361	1905	428	181	134	45	355	57	1676	459	751	734	2524	495	245	899	1484
16	36	1016	499	1427	1479	444	28	1198	1361	1905	428	181	134	45	355	57	1676	459	751	734	2524	495	245	899	1484	37
17	1016	499	1427	1479	444	28	1198	1361	1905	428	181	134	45	355	57	1676	459	751	734	2524	495	245	899	1484	37	36
18	499	1427	1479	444	28	1198	1361	1905	428	181	134	45	355	57	1676	459	751	734	2524	495	245	899	1484	37	36	1016
19	1427	1479	444	28	1198	1361	1905	428	181	134	45	355	57	1676	459	751	734	2524	495	245	899	1484	37	36	1016	499
20	1479	444	28	1198	1361	1905	428	181	134	45	355	57	1676	459	751	734	2524	495	245	899	1484	37	36	1016	499	1427
21	444	28	1198	1361	1905	428	181	134	45	355	57	1676	459	751	734	2524	495	245	899	1484	37	36	1016	499	1427	1479
22	28	1198	1361	1905	428	181	134	45	355	57	1676	459	751	734	2524	495	245	899	1484	37	36	1016	499	1427	1479	444
23	1198	1361	1905	428	181	134	45	355	57	1676	459	751	734	2524	495	245	899	1484	37	36	1016	499	1427	1479	444	28
24	1361	1905	428	181	134	45	355	57	1676	459	751	734	2524	495	245	899	1484	37	36	1016	499	1427	1479	444	28	1198
25	1905	428	181	134	45	355	57	1676	459	751	734	2524	495	245	899	1484	37	36	1016	499	1427	1479	444	28	1198	1361

문제의 영어 기대빈도와 Pearson χ^2 값을 비교했다.

$$\chi^2(k) = \sum_i \frac{(O_i - E_i)^2}{E_i}.$$

k	χ^2	k	χ^2
0	370761.744	13	240028.196
1	349320.551	14	150543.659
2	157067.547	15	275292.814
3	135052.934	16	301101.219
4	185318.110	17	100815.401
5	118927.980	18	123254.119
6	921.545	19	73448.724
7	290533.928	20	508237.438
8	167609.763	21	199549.637
9	357275.877	22	117261.345
10	144992.519	23	220336.935
11	564891.560	24	259621.119
12	68513.462	25	176043.833

$k = 6$ 의 값이 압도적으로 작다. 문제에서 주어진 암호문을 $k = 6$ (혹은 알파벳 G)을 사용하여 복호화 시

THE SOVEREIGNTY OF THE REPUBLIC OF KOREA SHALL RESIDE IN THE PEOPLE AND ALL STATE AUTHORITY SHALL EMANATE FROM THE PEOPLE

로 대한민국 헌법 영문본을 구할 수 있다.

첨부된 classifier.py --full-caesar-table은 각 후보의 A-Z 횟수까지 출력하며, --dump-caesar-dir DIR은 26개 전체 복호문과 TSV를 생성한다.

4 Vigenère key와 평문 복원

원본 두 파일은 157개 줄이고 대응 줄 길이가 같다. 반복 5-gram의 인접 출현 거리를 줄 경계를 넘지 않게 수집한 결과는 다음과 같다.

후보 period	나누어떨어지는 거리	비율
3	60/261	22.989%
4	56/261	21.456%
5	260/261	99.617%

우연한 반복 하나 때문에 전체 거리 GCD는 1이지만, 260/261이 5의 배수이고 문제의 $|k| \leq 5$ 조건이 있으므로 period는 5다. 줄마다 position modulo 5가 같은 문자를 합쳐 26개 Caesar shift를 비교했다.

위치	열 길이	shift	key	최소 χ^2
0	4047	10	K	222.518
1	4016	11	L	179.146
2	3975	21	V	406.928
3	3942	14	O	231.591
4	3917	9	J	165.249

따라서 key는 KLV0J다. 이 key를 각 줄 처음부터 다시 적용해야 한다는 사실도 두 방식의 문자별 대조로 검증했다.

key 적용 방식	Caesar 평문과 일치
줄마다 position 초기화	19,897 / 19,897
줄을 이은 연속 key	3,076 / 19,897

5 학습 분류기

5.1 데이터 분할과 feature

50자 이상인 대응 줄 쌍을 하나의 단위로 묶었다. 원래 줄 index가 5의 배수인 쌍은 holdout, 나머지는 train으로 보낸 것은 평균 Caesar 버전이 train에 있고 Vigenère 버전이 holdout에 있는 직접 누출을 막았다. 최종 표본은 train 218개, holdout 58개이며 class가 균형이다.

각 줄에서 전체 IC, Shannon entropy, 최적 Caesar 정규화 χ^2 , 최빈 문자 비율, lag 1-10 일치율 10개, period 2-5 열의 가중 평균 IC 4개로 총 18개 feature를 만든다. 이 feature들은 전역 shift에 불변이라 특정 Caesar shift 6은 제거된다. train 평균/표준편차로 표준화한 뒤 L2 logistic regression을 외부 패키지 없이 full-batch gradient descent로 1,500 epoch 학습했다.

	predicted Caesar	predicted Vigenère
actual Caesar	29	0
actual Vigenère	0	29

정확도 58/58은 동일한 대한민국 헌법 corpus와 동일한 두 암호화 key 간의 paired line holdout 결과다. 새로운 corpus, key, Vigenère 길이에 대한 일반화 성능으로 해석할 수 없다. 전역 shift는 제거했지만 고정 period 5와 corpus에 특화될 가능성은 남아 있다. 배포물에 외부 corpus가 없으므로 별도 corpus/key 실험 결과를 만들어 적지 않았다.

5.2 네 짧은 암호문과 최종 라벨

번호	$P(V)$	모델 구조 판정	최적 shift	출제 의도 추정
1	0.017058	Caesar-like	6	Caesar
2	0.017058	Caesar-like	10	Vigenère
3	0.089193	Caesar-like	10	Vigenère
4	0.089193	Caesar-like	6	Caesar

네 암호문은 모두 하나의 고정 shift로 자연스러운 영어가 되어 관측 구조는 period-10이다.

2번을 Vigenère key K로 만들었다는 가설과 Caesar shift 10으로 만들었다는 가설은 암호문만으로 구별할 수 없다. 다만 shift 6이 복원된 Caesar key, shift 10이 KLV0J의 첫 글자 K와 일치한다. 이 생성기 단서에 따른 출제 의도상 직접 답은

Caesar, Vigenère, Vigenère, Caesar

로 제출한다. 동시에 이 목록은 식별 가능한 암호 구조가 아니라 숨은 생성 방식을 추정한 값임을 명시한다.

6 재현

Python 3.10 이상 표준 라이브러리만 필요하다.

```
python3 classifier.py --problem-zip 1암호분석_.zip
python3 classifier.py --problem-zip 1암호분석_.zip --full-caesar-table
python3 classifier.py --problem-zip 1암호분석_.zip \
--dump-caesar-dir /tmp/problem01-caesar
```

실행은 다음을 출력하고 검증한다.

- IC, 모든 Caesar 후보, Kasiski와 열별 key
- line-reset 대조와 paired holdout confusion matrix
- 네 표본의 확률, shift, 평문

두 번째 명령은 26개 key 각각의 복호문과 A-Z 빈도, 카이제곱 값을 표준 출력에 모두 싣는다. 세 번째 명령은 같은 26개 복호문과 빈도 TSV를 개별 파일로 저장한다. 따라서 본문의 요약 순위표뿐 아니라 원문 3-가가 요구한 모든 key별 결과를 제출 코드에서 그대로 재생성할 수 있다.

마지막 self-checks: PASS가 모든 수치와 답을 검증한다.

7 참고 자료

- William F. Friedman, *The Index of Coincidence and Its Applications in Cryptanalysis*: 단일·다중 알파벳 암호의 빈도와 IC 판정 근거.
- Friedrich W. Kasiski, *Die Geheimschriften und die Dechiffrier-Kunst*: 반복 문자열 간격의 공약수로 key 길이를 추정하는 절차.
- Karl Pearson, *On the Criterion that a Given System of Deviations from the Probable ...*: 관측 빈도와 영어 기대빈도의 카이제곱 비교.
- Claude E. Shannon, *A Mathematical Theory of Communication*: 분류기의 문자분포 entropy feature.
- D. R. Cox, *The Regression Analysis of Binary Sequences*: binary logistic regression 모델의 배경.